

# PREDICCIÓN DEL RUIDO VEHICULAR UTILIZANDO REDES NEURONALES ARTIFICIALES

Martín E. Sequeira<sup>†</sup>, Víctor H. Cortínez<sup>†‡</sup> y Adrián P. Azzurro<sup>†</sup>

<sup>†</sup>*Centro de Investigaciones en Mecánica Teórica y Aplicada, Universidad Tecnológica Nacional, Facultad Regional Bahía Blanca, 11 de Abril 461, 8000 Bahía Blanca, Argentina, [martins@frbb.utn.edu.ar](mailto:martins@frbb.utn.edu.ar), [vcortine@frbb.utn.edu.ar](mailto:vcortine@frbb.utn.edu.ar), [azzurro@frbb.utn.edu.ar](mailto:azzurro@frbb.utn.edu.ar)*

<sup>‡</sup>*Departamento de Ingeniería Universidad Nacional del Sur, Alem 1253, 8000 Bahía Blanca, Argentina*

<sup>^</sup>*Consejo Nacional de Investigaciones Científicas y Técnicas (CONICET)*

**Resumen:** En este trabajo se utiliza un enfoque basado en Redes Neuronales Artificiales (RNAs) para obtener un modelo de predicción de ruido de tráfico rodado en un entorno urbano virtual. Los datos relacionados con las características del flujo vehicular y el entorno del espacio urbano se consiguen a partir de un modelo geométrico, basado en el método de trazado de rayos, implementado en el programa SoundPLAN. Con estos datos se analizan diferentes estructuras de RNAs a efectos de obtener un modelo preciso para la estimación de los niveles sonoros. Finalmente, se muestra que el presente enfoque exhibe una gran capacidad de aproximación al contemplar las variables involucradas.

**Palabras claves:** *redes neuronales artificiales, ruido de tráfico, predicción sonora*

2000 AMS Subjects Classification: 68T20

## 1. INTRODUCCIÓN

La contaminación sonora constituye un gran problema en los ambientes urbanos actuales. En este contexto, el ruido del tráfico rodado es, evidentemente, la fuente más molesta [1]. Con el fin de evaluar y controlar los niveles sonoros en zonas urbanas es importante la utilización de modelos matemáticos que permitan estimar el ruido del tráfico a partir de una serie de parámetros asociados. Los modelos tradicionales se caracterizan, en general, por fórmulas semi-empíricas basadas en técnicas de regresión lineal [2]. Asimismo, algunos de estos modelos suelen ser implementados en programas computacionales, basados en la técnica de trazado de rayos, como por ejemplo SoundPLAN [3], [4]. Sin embargo, muchas veces los modelos clásicos de predicción pueden resultar limitados para explicar las relaciones entre el entorno y las fuentes sonoras involucradas.

Un enfoque alternativo en estos casos es el uso de meta-modelos generados a partir de la técnica de Redes Neuronales Artificiales (RNAs). Los metamodelos son, en general, elaborados a partir de valores experimentales o datos numéricos simulados por técnicas computacionales robustas. Luego, el enfoque consiste en analizar distintas configuraciones urbanas considerando diferentes variables relacionadas con el flujo vehicular y las características del entorno y obtener estimaciones del nivel sonoro. Estos datos se utilizan para ajustar una red neuronal, siendo esta última, esencialmente una técnica de regresión no lineal que permiten efectuar una compleja interpolación para detectar patrones ocultos a partir de la información para el sistema dado [5]. Esta herramienta actúa como un modelo de caja negra y puede ser utilizada en situaciones en las cuales no se cuenta con el conocimiento necesario para establecer modelos matemáticos adecuados que representen el sistema. Su principal ventaja consiste en englobar en un único modelo empírico una gran cantidad de relaciones entre causas y efectos para distintos escenarios, lo que permite simular cualquier situación intermedia de una manera efectiva y con un costo computacional muy bajo [6]. Los modelos basados en RNAs presentan una gran flexibilidad pero la selección de sus parámetros de diseño depende fuertemente del tipo de problema a resolver, ya que no existe una única metodología que permita obtener la estructura más adecuada. En general, es posible recurrir a la experiencia basada en problemas similares o, en la mayoría de los casos, es necesario realizar varias pruebas con diferentes configuraciones de estructuras para definir la más correcta.

En este trabajo se analizan dos tipos de estructuras para la predicción del ruido del tráfico en un sector urbano virtual: el perceptron multicapa MLP (MultiLayer Perceptron) y el modelo de regresión generalizada GRNN (General Regression Neural Networks), siendo este último un caso especial de las redes de funciones de base radial RBF (Radial Basis Function). Los datos para la generación y

entrenamiento de las redes se obtienen numéricamente a partir de un modelo computacional, implementado en el programa SoundPLAN. Luego, se comprueba la eficacia de las RNAs estimando los niveles sonoros para un conjunto de datos no utilizados en la etapa de entrenamiento. Este enfoque ha sido implementado por los autores en trabajos previos relacionados con la predicción del ruido en ambientes industriales interiores [7], [8]. En particular, el presente trabajo es complementario a otro publicado por los autores en el año 2019 [9].

## 2. METODOLOGÍA

### 2.1. GENERACIÓN DE ESCENARIOS VIRTUALES

El indicador acústico más adecuado para representar el ruido proveniente del tráfico vehicular es el nivel sonoro continuo equivalente con ponderación A, LAeq, en dBA. Este nivel depende de varios parámetros tales como la cantidad y tipología del flujo vehicular, sus velocidades y las características geométricas de la calzada y su entorno [10]. En tal sentido, se adoptaron cinco variables de entrada asociadas al nivel sonoro: número de vehículos ligeros (VL), número de vehículos pesados (VP), velocidad media del flujo vehicular (V), ancho de la calzada (A) y altura media de edificación (H). A los efectos de contemplar información real de las variables de estudio, los rangos se seleccionaron teniendo en cuenta datos relevados en un estudio previo en la zona del micro-centro de la ciudad de Bahía Blanca, Argentina [4]. En la Tabla 1 se muestran dichos rangos [9].

Los niveles sonoros (LAeq) se simularon empleando el modelo de cálculo de ruido de tráfico francés NMPB Routes-96 [11] implementado en el programa SoundPLAN. Los motivos de su elección se deben principalmente a que dicho modelo ha mostrado un buen comportamiento en ciudades sudamericanas [4].

Para la confección de los escenarios se consideraron diferentes flujos vehiculares y tipologías de vías de comunicación definiendo distintas velocidades medias del flujo y anchos de calzada. A partir de esto, se estimaron un total de 140 valores del LAeq en 52 puntos receptores distribuidos en una zona urbana virtual de aproximadamente 0.8 km<sup>2</sup>. Se contemplaron las manzanas urbanas como bloques compactos con diferentes alturas medias. Los espacios verdes (plazas), considerados dentro de la zona de estudio, se caracterizaron por una absorción promedio superficial correspondiente a vegetación.

	Vehículos livianos (VL) [veh./h]	Vehículos pesados (VP) [veh./h]	Velocidad media (V) [km/h]	Ancho calle (A) [m]	Altura media edificación (H) [m]	LAeq [dBA]
Máximo	1500	50	60	18	20	76.6
Mínimo	50	0	30	5	5	60.1

Tabla 1: Rango de las variables de estudio.

### 2.2. MODELOS DE REDES NEURONALES

A efectos de seleccionar la estructura final del modelo de red neuronal, se evaluaron tres configuraciones diferentes. La simulación se realizó utilizando el toolbox de redes neuronales implementado en el programa MATLAB y, por simplicidad, se emplearon los nombres de las funciones de MATLAB para los distintos algoritmos. Las configuraciones 1 y 2 se corresponden con una red tipo MLP caracterizadas por un entrenamiento a través de un aprendizaje supervisado mediante el algoritmo de retro-propagación del error, utilizando la técnica de optimización Levenberg-Marquardt [5]. En particular, en la configuración 1 se utilizó el algoritmo de enteramiento "trainlm" (variante de Levenberg-Marquardt) y en la configuración 2 se empleó el algoritmo "trainbr" (variante de Levenberg-Marquardt con regulación bayesiana). En ambos casos, se utilizaron las funciones transferencia "tansig + purelin". La configuración 3 se corresponde con una Red de Regresión Generalizada "newgrnn" considerada un tipo de Red de Función de Base Radial normalizada, donde existen tantas neuronas en la capa oculta como vectores de entrada existen en el conjunto de entrenamiento. Esta red aproxima la función que existe entre las entradas y la salida, empleando la técnica estadística de regresión no-lineal [12].

Se consideraron cinco neuronas de entrada: VL, VP, V, A y H (ver sección 2.1), una capa oculta con 10 neuronas (configuraciones 1 y 2) y una neurona de salida correspondiente al valor del LAeq. El conjunto total de datos simulados (140 muestras) se dividió en tres sub-conjuntos: grupo de aprendizaje (87

muestras), de validación (21 muestras) y de verificación (32 muestras). Los dos primeros grupos se utilizaron para entrenar la red. En particular, para las redes tipo MLP, el grupo de aprendizaje permite estimar los parámetros (pesos) de la red, mientras que el grupo de validación se utiliza para estimar el error de generalización, es decir, la tasa de predicción incorrecta con datos diferentes a los utilizados en el proceso de aprendizaje. Finalmente, para estimar la capacidad de predicción de los modelos de red neuronal se utiliza el grupo de datos de verificación, los cuales no fueron utilizados durante la etapa de entrenamiento.

### 3. RESULTADOS

Para cuantificar el error entre los valores simulados (SoundPLAN) y estimados, se utilizaron los siguientes estimadores estadísticos: el error máximo absoluto MAE (Maximum Absolute Error), la raíz del error cuadrático medio RMSE (Root Mean Square Error) y el coeficiente de determinación  $R^2$ . En la Tabla 2 se observa la eficacia de aproximación de las distintas estructuras de RNAs, en función de los estimadores mencionados, para los conjuntos de entrenamiento y verificación. Se aprecia que el ajuste de las tres configuraciones es muy bueno donde, en particular, las redes tipo MLP (configuraciones 1 y 2) presentan una mejor aproximación.

A modo complementario, en la Figura 1 se observan las comparaciones de los valores del LAeq simulados y aquéllos estimados para cada configuración de RNA considerando el conjunto de datos de verificación. A partir de los resultados se puede observar la gran capacidad de los modelos para aproximar la relación no lineal entre las características del flujo vehicular y su entorno y el nivel de ruido generado.

RNA	Entrenamiento			Verificación		
	MAE	RMSE	$R^2$	MAE	RMSE	$R^2$
Configuración 1	0.98	0.17	0.997	0.92	0.44	0.991
Configuración 2	1.09	0.22	0.996	1.20	0.53	0.988
Configuración 3	2.24	0.86	0.940	3.17	1.16	0.906

Tabla 2: Eficacia de predicción de las distintas configuraciones de RNAs.




Figura 1: Comparación del LAeq simulado (—●—) y estimado (---●---) para el conjunto de datos de verificación. Configuraciones 1, 2 y 3.

### 4. CONCLUSIÓN

En este trabajo se analizaron distintas tipologías de RNAs a los efectos de generar un modelo de predicción del nivel sonoro debido al tráfico vehicular en un ambiente urbano virtual. Para ello, se simularon diferentes escenarios, contemplando distintas características del flujo vehicular y de la geometría del entorno, mediante la utilización de un modelo robusto de trazado de rayos implementado en el programa SoundPLAN. Con esta información se generaron los modelos de RNAs los cuales demostraron una alta capacidad de aproximación. En particular, la red tipo MLP (configuración 1) presenta el mejor desempeño para la situación planteada.

Actualmente, los autores están trabajando en la implementación de esta metodología en un ambiente urbano real.

## AGRADECIMIENTOS

Los autores agradecen el apoyo de la Secretaría de Ciencia y Tecnología de la Universidad Tecnológica Nacional, del departamento de Ingeniería de la Universidad Nacional del Sur y de CONICET.

## REFERENCIAS

- [1] V. PATHAK, B.D. TRIPATHI, AND V. KUMAR MISHRA, *Evaluation of traffic noise pollution and attitudes of exposed individuals in working place*, Atmos. Environ., 42 (2008), pp.3892-3898.
- [2] N. GARG, AND S. MAJI, *A critical review of principal traffic noise models: Strategies and implications*. Environ. Impact. Assess. Rev., 46 (2014), pp.68-81.
- [3] J.E. GUARDERAS ROSALES, *Evaluación de modelos de predicción de ruido de tráfico aplicados a la ciudad de Quito mediante el software Soundplan 6.3*, Bachelor's thesis, Quito: Universidad de las Américas, 2011.
- [4] M.E. SEQUEIRA, AND V.H. CORTÍNEZ, *Estudio acústico de la ciudad de Bahía Blanca mediante un modelo computacional*. Mecánica Computacional, 31 (2012), pp.4057-4080.
- [5] C.M. BISHOP, *Neural Network for pattern recognition*, Oxford, U.K., Oxford Univ. Press, 1995.
- [6] D.J. FONSECA, D.O. NAVARESSE, AND G.P. MOYNIHAN, *Simulation metamodeling through artificial neural networks*. Eng. Appl. Artif. Intell., 16 (2003), pp.177-183.
- [7] V.H. CORTÍNEZ, AND M.E. SEQUEIRA, *Un enfoque híbrido para el rediseño acústico óptimo de recintos industriales*, Mecánica Computacional, 28 (2009), pp. 39-61.
- [8] M.E. SEQUEIRA, AND V.H. CORTÍNEZ, *Optimal acoustic design of industrial buildings by means of a hybrid model*. In Proceedings of the 18th International Congress on Sound and Vibration (ICSV18), (2011), Formato digital.
- [9] M.E. SEQUEIRA, V.H. CORTÍNEZ, AND A.P. AZZURRO, *Caracterización Acústica de Ambientes Urbanos Mediante el Uso de Redes Neuronales*. Mecánica Computacional, 37(2019), pp.97-105.
- [10] V. NEDIC, D. DESPOTOVIC, S. CVETANOVIC, M. DESPOTOVIC, AND S. BABIC, *Comparison of classical statistical methods and artificial neural network in traffic noise prediction*. Environ. Impact. Assess. Rev., 49(2014), pp. 24-30.
- [11] M. WALLSTROM, *Guidelines on the revised interim computation methods for industrial noise, aircraft noise, road traffic noise and railway noise, and related emission data*. OJEU., 2003.
- [12] D.F. SPECHT, *A General Regression Neural Network*, IEEE Trans. Neural. Netw., 2(1991), pp.568-576.